2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 8

Maidana Medernach, Luciano

Segonds, Delfina

Gutheim, Luciana

1. Introducción

Hoy en día, el consumo de alimentos procesados y ultraprocesados es mucho mayor que hace algunos años. Según la OMS una alimentación equilibrada debe incluir una variedad de alimentos que cubran las necesidades energéticas y nutricionales diarias de cada persona, pero para mantener una dieta equilibrada es necesario conocer que contienen los alimentos que ingerimos. Leer y entender la información nutricional de los productos permite detectar ingredientes poco saludables como azúcares añadidos, sodio o grasas trans y comparar productos para elegir las mejores opciones. Muchas veces consumimos alimentos sin considerar la calidad nutricional y el impacto que pueden tener en nuestra salud.

Para analizar este problema, trabajamos con el dataset *Global Food & Nutrition del año 2026,* que contiene información sobre una variedad de productos de la industria alimentaria, junto con sus características y atributos nutricionales.

La información que contiene está extraída a partir de la centralización de datos del Departamento de Agricultura de los Estados Unidos (USDA), complementada con la información de Open Food Facts, una base de datos de productos alimenticios desarrollada con la colaboración de voluntarios de distintos países.

En la base de datos podemos encontrar datos básicos (nombre, marca, ingredientes y categorías) y la cantidad de nutrientes medidos por cada 100 gramos de producto (calorías, proteínas, grasas, grasas saturadas, carbohidratos, azúcares, fibras, proteínas, sodio, sal). También se incluye clasificaciones útiles sobre cada producto:

- NutriScore: mide el grado nutricional, es decir la cantidad y calidad de los nutrientes, esenciales para mantener las funciones vitales del cuerpo, que un producto aporta al organismo. Es una buena medida para comprender qué tipo de energía se consume y cómo contribuye a la salud. La clasificación de Nutri Score se refleja mediante un sistema de letras, de la A a la E, señalando de mejor a peor los alimentos.
- Alérgenos Alimenticios: muchos alimentos contienen alérgenos que son sustancias presentes en los alimentos que pueden desencadenar una reacción alérgica en algunas personas. Es importante conocer qué productos pueden contener alérgenos, ya que la única forma de tratar una alergia alimentaria es evitar el alimento que provoca la enfermedad. En el dataset se identifican los alérgenos alimentarios más comunes (gluten, lactosa, nueces, pescado, soja y huevos) por una variable booleana para cada alimento, tambien bajo una lista de alergenos.

- Clasificación NOVA: clasifica todos los alimentos y productos alimenticios en cuatro grupos según el alcance y el nivel del procesamiento industrial al que se someten. El Grupo 1 incluye alimentos naturales o mínimamente procesados, como frutas, verduras, huevos, leche o carnes, que pueden haber pasado por procesos simples para conservarlos o hacerlos aptos para el consumo. El Grupo 2 está formado por ingredientes culinarios procesados, como aceite, manteca, azúcar y sal, que se utilizan principalmente para preparar o condimentar otros alimentos. El Grupo 3 corresponde a alimentos procesados, que se obtienen al agregar ingredientes del Grupo 2 a alimentos del Grupo 1, como quesos, conservas o panes. Por último, el Grupo 4 incluye los alimentos ultraprocesados, que son productos elaborados a partir de varios ingredientes y aditivos, como gaseosas, snacks, productos de carne procesados y comidas congeladas listas para consumir.
- Eco-Score: Otra medida que tienen los productos alimentarios, el eco-score, el cual es un sistema de rating que evalúa su impacto ecológico desde low-impact (bajo impacto) a high-impact (alto impacto). Es esencial para generar conocimiento hacia los consumidores del impacto de su elección de comidas para generar que las empresas tengan en cuenta las prácticas sostenibles al producirlos. Se mide por las letras de la A a la E, siendo A el impacto ambiental más bajo y E el más alto.

Para llevar a cabo este trabajo, en primer lugar se investigó sobre el dominio para poder conocer mejor los datos y realizar una exploración inicial de la base. A partir de esta investigación, se pudo observar que el dataset permite analizar diferentes características nutricionales de los productos y estudiar posibles relaciones entre ellas. Luego, se realizó un análisis preliminar que incluyó la limpieza y preparación de los datos. Con la base preparada, se plantearon y realizaron las pruebas correspondientes a las hipótesis univariadas y bivariadas. Por último, se planteó una hipótesis multivariada y se realizaron las pruebas necesarias para analizarla.

El proceso de este análisis se encuentra documentado en el presente informe y se entrega junto con un repositorio de GitHub. El trabajo está organizado en distintas secciones, comienza con un análisis exploratorio de los datos. A continuación, se presentan las seis hipótesis planteadas, junto con la estrategia utilizada para abordarlas y los resultados obtenidos. Por último, se desarrollan las conclusiones obtenidas a partir del análisis realizado.

2. Análisis exploratorio de los datos

Como comienzo de nuestro análisis preliminar de los datos, identificamos las principales variables junto con su media, desvío, mínimos y máximos (en las cuales correspondía) [Sección 1.1].

Variable	Tipo	Subtipo	Descripción
product_name	Cualitativa	Nominal	Nombre del producto
brands	Cualitativa	Nominal	Marca o marcas del producto
categories	Cualitativa	Nominal	Categorías a las que pertenece
ingredients	Cualitativa	Nominal	Lista de ingredientes
nutriscore_grade	Cualitativa	Ordinal	Grado nutricional ordenado de A a E
nova_group	Cualitativa	Ordinal	Grupo de procesamiento, de 1 a 4
ecoscore_grade	Cualitativa	Ordinal	Grado ambiental ordenado de A-plus a F (*en este dataset se usa esta clasificación*)
allergens	Cualitativa	Nominal	Alérgenos declarados
energy_kcal	Cuantitativa	Continua	Cantidad de energía en kcal
fat_100g	Cuantitativa	Continua	Gramos de grasa por 100 g
saturated_fat_100g	Cuantitativa	Continua	Gramos de grasa saturada por 100 g
carbs_100g	Cuantitativa	Continua	Gramos de carbohidratos por 100 g

sugars_100g	Cuantitativa	Continua	Gramos de azúcares por 100 g
fiber_100g	Cuantitativa	Continua	Gramos de fibra por 100 g
proteins_100g	Cuantitativa	Continua	Gramos de proteínas por 100 g
salt_100g	Cuantitativa	Continua	Gramos de sal o equivalente de sal por 100 g
sodium_100g	Cuantitativa	Continua	Gramos de sodio por 100 g
contains_gluten	Cualitativa	Nominal dicotómica	Contiene gluten
contains_dairy	Cualitativa	Nominal dicotómica	Contiene lactosa
contains_nuts	Cualitativa	Nominal dicotómica	Contiene frutos secos
contains_soy	Cualitativa	Nominal dicotómica	Contiene soja
contains_eggs	Cualitativa	Nominal dicotómica	Contiene huevo
contains_fish	Cualitativa	Nominal dicotómica	Contiene pescado
food_type	Cualitativa	Nominal	Tipo de producto

Nos percatamos de que el valor de food_type era constante, por lo que decidimos eliminar la variable [Sección 1.2].

Análisis de nulos

Posteriormente pasamos al análisis de nulos, donde encontramos una tasa alta de nulos en ciertas variables [Sección 2.1]. Tanto los alérgenos como la fibra tenían alrededor del 33% de valores nulos. Con respecto a la fibra, aunque conceptualmente podrían corresponder a ceros, se optó por no imputarlos para no distorsionar artificialmente la distribución. Con respecto a los valores nulos en los alérgenos, podían significar ausencia de alérgenos o ausencia de información. Optamos por la segunda, ya que no teníamos información suficiente para asegurar la ausencia de alérgenos.

Identificamos también que a pesar de no contar con una cantidad de valores nulos significante, ecoscore_grade contaba con 777 valores UNKNOWN y 259 NOT-APPLICABLE. Los valores UNKNOWN fueron traducidos a nulos [Sección 2.2]. Los valores NOT-APPLICABLE son analizables.

El resto de valores nulos rondan entre el 5 y el 10%, los cuales son tratados particularmente cuando nos centramos en las hipótesis a tratar. Existen gran cantidad de valores ceros en los nutrientes o componentes cada 100 gramos, pero son válidos en el contexto.

Analizando los registros observamos el formato particular que tenían la variable “ingredients” y la variable “categories”. Los datos analizados fueron obtenidos de un sitio llamado Open Food Facts, el cual permite a personas de todo el mundo participar y agregar productos. Por ello, no existe un formato específico, ni tampoco un idioma específico, en los textos de categoría e ingredientes. Esto significó una complicación a la hora utilizar dichas variables para análisis, las decisiones que tomamos para su normalización son explicadas más adelante.

En el dataset obtuvimos además de los alérgenos, las variables booleanas que indican presencia de alimentos que provocan las causas más comunes de alergia. Dichas columnas parecen haber sido generadas buscando la presencia de palabras claves. Identificamos un caso de falla puntual, donde el producto en sus ingredientes explicitaba “pt:isento-de-gluten” que significa libre de gluten en portugués, sin embargo, la variable booleana de contiene gluten tenía un valor positivo. Decidimos no eliminar la columna de alérgenos porque nos proporciona información de alergias fuera de las principales, y para contrastar en casos puntuales las variables booleanas.

Registros duplicados

Además de los valores nulos, decidimos estudiar los registros duplicados. Al buscar registros duplicados exactos, con los mismos valores en todas las columnas, encontramos 38, de las cuales tan solo 2 tenían valores reales, mientras las otras solo valores NaN, decidimos eliminar todas las duplicadas [Sección 3.1].

No solo buscamos duplicados exactos, también decidimos buscar registros que coincidieran en nombre y marca. ¿El resultado? 289 registros con similitudes de nombres y marcas [Sección 3.2]. Descargamos los datos para analizarlos manualmente. Encontramos que mientras algunos productos varían en ciertas componentes (como la sal), otros productos eran prácticamente idénticos, con diferencias en la forma de nombrar los ingredientes, o por mayúsculas/minúsculas. Determinamos que la causa de estas duplicaciones es la libertad de utilización de la pagina open food facts, y la existencia del mismo producto en distintos países. Algunos casos:

Caso mayonesa HEINZ: tiene dos entradas exactamente iguales pero cambia la cantidad de grasas saturadas. ¿Son dos productos distintos? ¿Se debe a una regulación en cada país?

Lo mismo sucede en las almendras de Plenish, un producto tiene más sal que otro ¿unas almendras tienen sal agregada y otras no?

No podemos diferenciar productos por región o por versiones light/sin azucares/sin sal agregada si no se explicita en el nombre o las categorías. Por tanto, realizar una limpieza de duplicados en base al nombre y marca, teniendo en cuenta además una variación mínima en sus valores nutricionales. Si eliminamos todos los casos en donde una unidad muestral tiene mismo nombre y marca que otra, no sería correcto, porque únicamente con esa información no se puede determinar si corresponden al mismo producto, podrían ser variantes. Si un producto tiene una diferencia relativa mayor al 5%, o una diferencia absoluta de 1,5g en las categorías, es considerado un producto diferente, sino se elimina como duplicado [Sección 3.3]. Estos umbrales se utilizaron como un criterio práctico para distinguir pequeñas variaciones en los datos de diferencias que podrían corresponder a productos distintos.

Outliers

Identificamos varios valores imposibles en las cantidades cada 100g desde el momento que vimos los máximos en el análisis inicial (por ejemplo, 9000g de carbohidratos por 100g de comida). Invalidamos todos los valores que superen el umbral de 100g [Sección 4.1].

Identificamos además posibles valores atípicos mediante el criterio del rango intercuartílico. Se consideraron atípicos los valores inferiores a Q1 − 1,5 x IQR o superiores a Q3 + 1,5 x IQR. Encontramos una cantidad significativa de outliers [Sección 4.2]. Es importante mencionar que, un valor atípico no necesariamente representa un error, ya que algunos alimentos pueden presentar concentraciones naturalmente elevadas de determinados nutrientes. Utilizamos el criterio del rango intercuartílico para detectar valores que requieren una revisión, no para eliminarlos automáticamente.

Analizamos manualmente los valores energéticos ya que se trataba de tan solo dos valores muy altos. Al revisarlos nos damos cuentas de incongruencias, como que la grasa y los carbohidratos suman más de 100g, o que un producto tiene 76g de proteina sin grasa pero 1500kcal, decidimos imputarles ambos valores nulos en la energía para que no interfiera en gráficos ni análisis posteriores [Sección 4.3].

Gráficos iniciales

Para comenzar a entender mejor la relación entre nuestras variables, realizamos una matriz de dispersión con todas las variables cuantitativas (también fue incluida NOVA, ya que a pesar de ser categórica está expresada con valores discretos entre 1 y 4) [Sección 5.1].

Lamentablemente no nos ofreció mucha información. Pudimos observar relaciones entre las variables, pero en cuanto a restricciones químicas en cómo se forman los alimentos. Por ejemplo, los azúcares son carbohidratos, y por tanto al aumentar la cantidad de azúcar, también lo hacen los carbohidratos. Lo mismo sucede con la grasa y la energía calórica, tienen una correlación positiva.

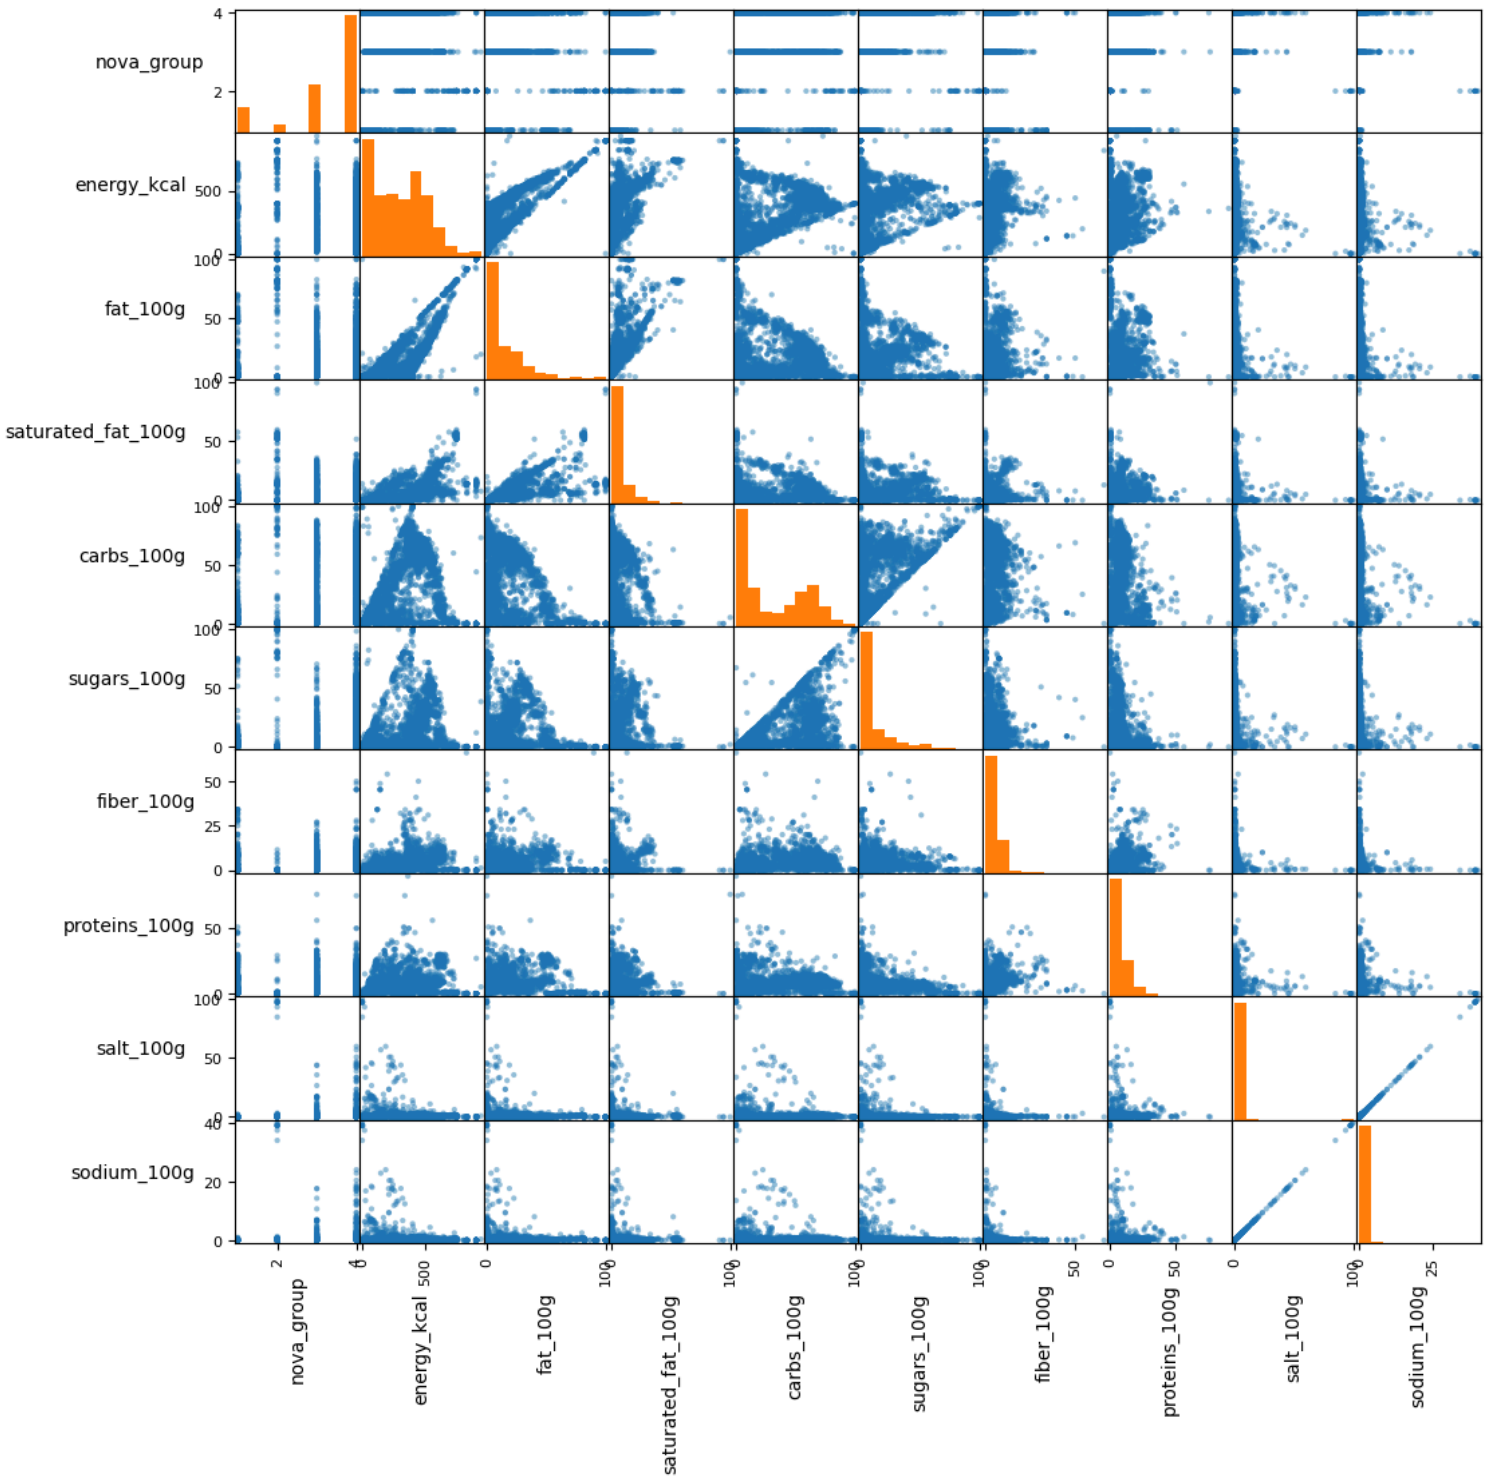


Fig 1: Matriz de dispersión entre las variables cuantitativas del dataset.

Como el sodio se calcula a partir de la cantidad de sal, decidimos eliminar la variable sodium_100g del dataset, ya que claramente una depende de la otra [Sección 5.2]. La cantidad de sal puede estimarse multiplicando la cantidad de sodio por 2,5. Decidimos conservar la variable salt_100g, ya que permite interpretar más fácilmente el contenido de sal de los productos.

Posteriormente decidimos analizar la distribución de los valores de cada variable cuantitativa. El primer intento resultó en gráficos con cajas muy comprimidas debido a outliers extremos. Por ello, eliminamos el 1% superior de los datos de cada variable para graficar [Sección 5.3].

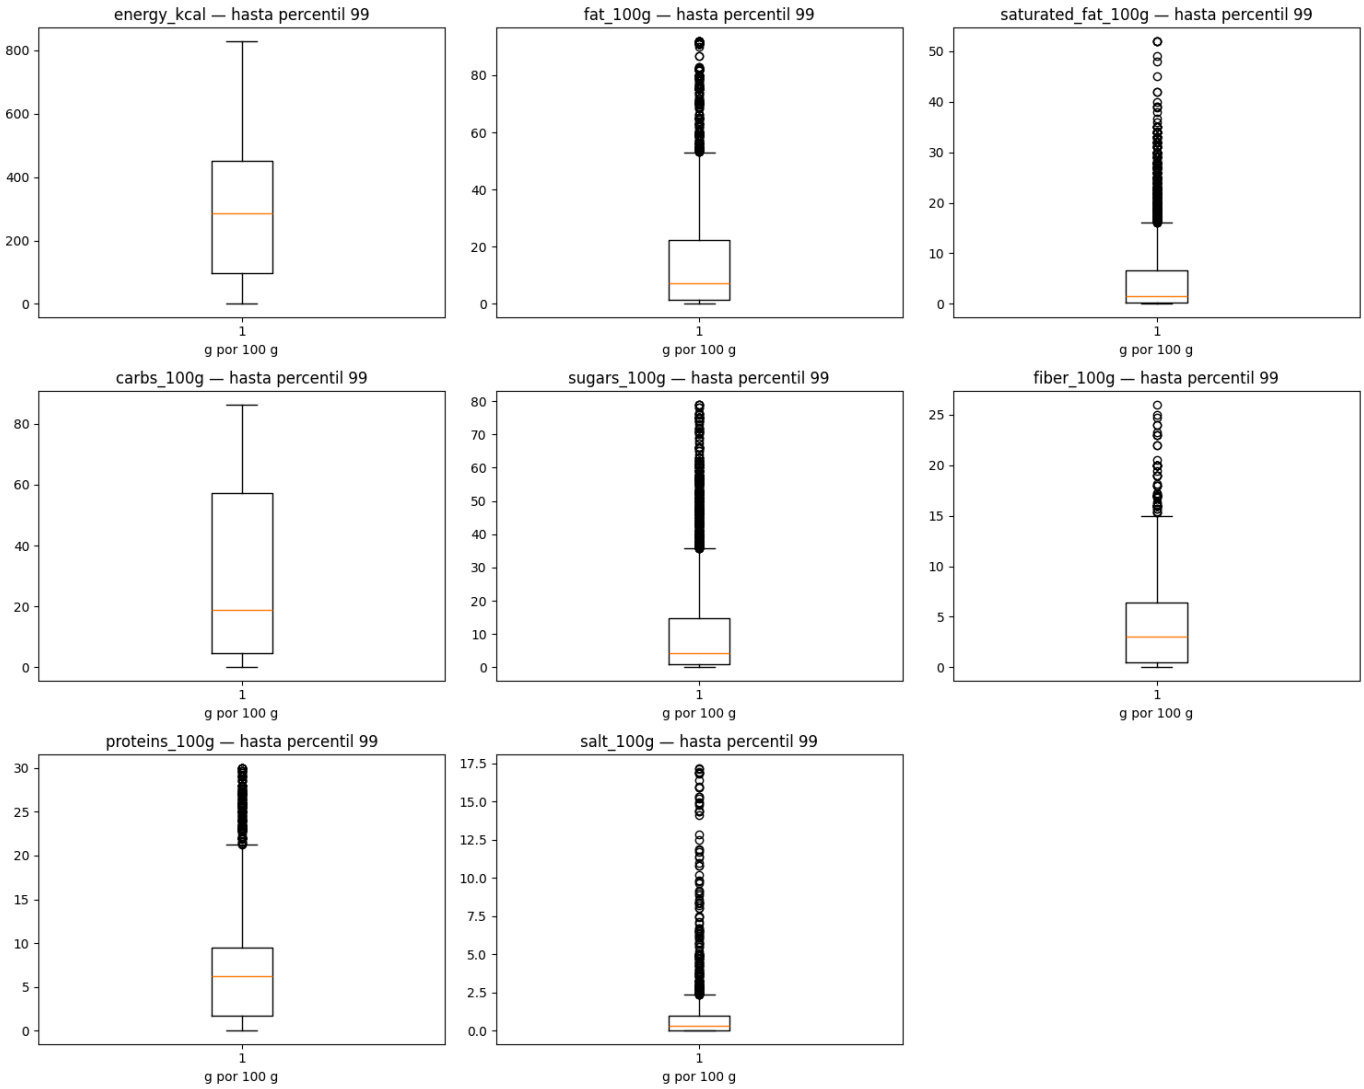


Fig 2: boxplots de las variables cuantitativas del dataset (excluyendo nova)

Tanto en el boxplot como en el histograma realizado posteriormente [Sección 5.4], se observa que, exceptuando carbohidratos y calorías, las variables suelen concentrar la mayoría de sus valores en valores bajos, teniendo cola hacia la derecha. Ninguna de las variables parece seguir una distribución conocida.

Normalización de categorías

Como las variables cuantitativas no nos ofrecieron mucha información por sí solas, decidimos normalizar las categorías para hacer análisis de relaciones entre las categorías de los productos y las demás variables. Para ello utilizamos IA para que genere un diccionario donde agrupe en clases más amplias las categorías que fuese encontrando en el dataset [Sección 6.1]. De 355 categorías diferentes, pasamos a tener 26.

Existía una clasificación “No alimentario / medicamentos”, comprobamos manualmente que se trataba de cremas, cigarrillos, antibióticos, que consideramos no eran adecuados para el análisis. Fueron eliminados [Sección 6.2].

De la nueva categorización generada, 633 productos quedaron sin clasificar debido a falta de categorías, categorías demasiado genéricas que no ofrecían información o debido a categorías que no tenían un significado real.

Agrupamos nuevamente de las 26 categorías para poder graficar, obtuvimos 10 categorías generales y una categoría de “otros”. Decidimos utilizar las 10 categorías principales para analizar su relación con ecoscore [Sección 6.3] y posteriormente con nova [Sección 6.4].

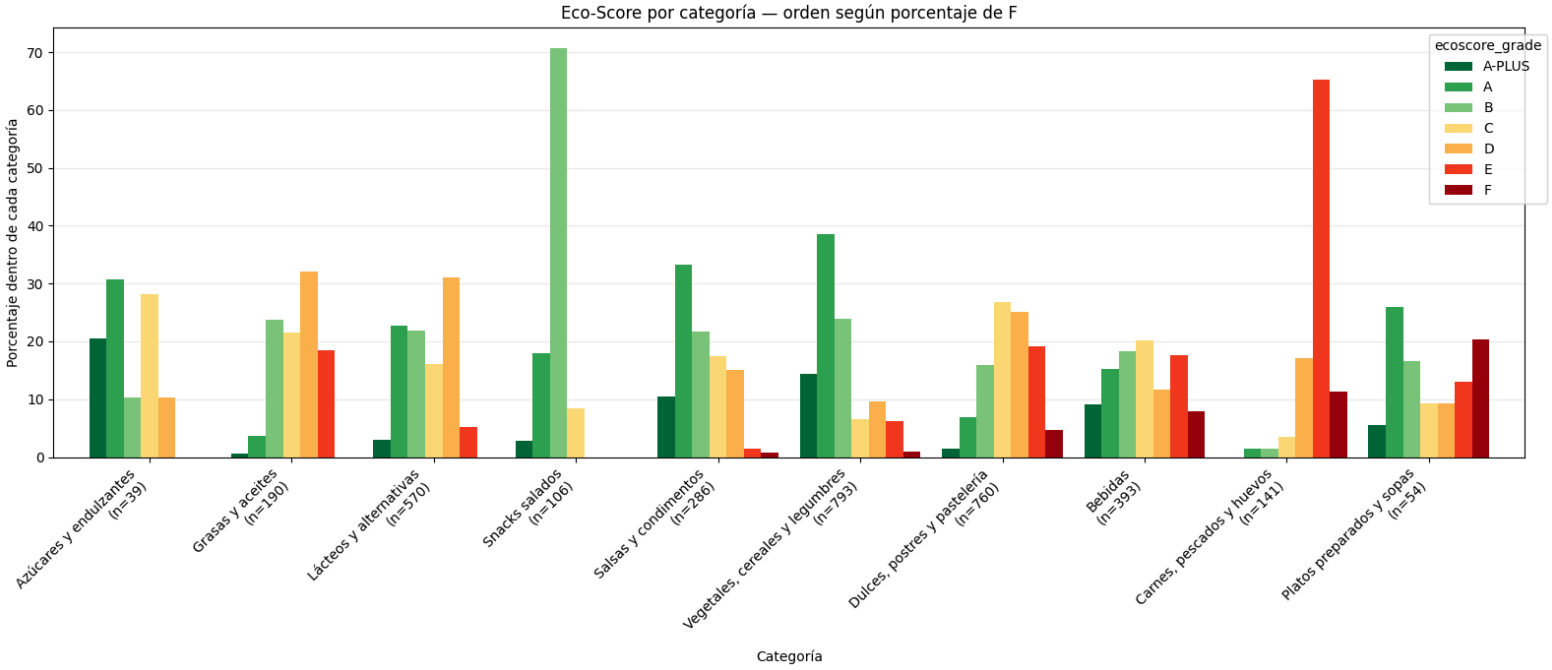


Fig 3: Gráfico de barras agrupadas por categoría, muestran porcentaje de productos con los distintos valores ecoscore, ordenados por porcentaje de productos con ecoscore F.

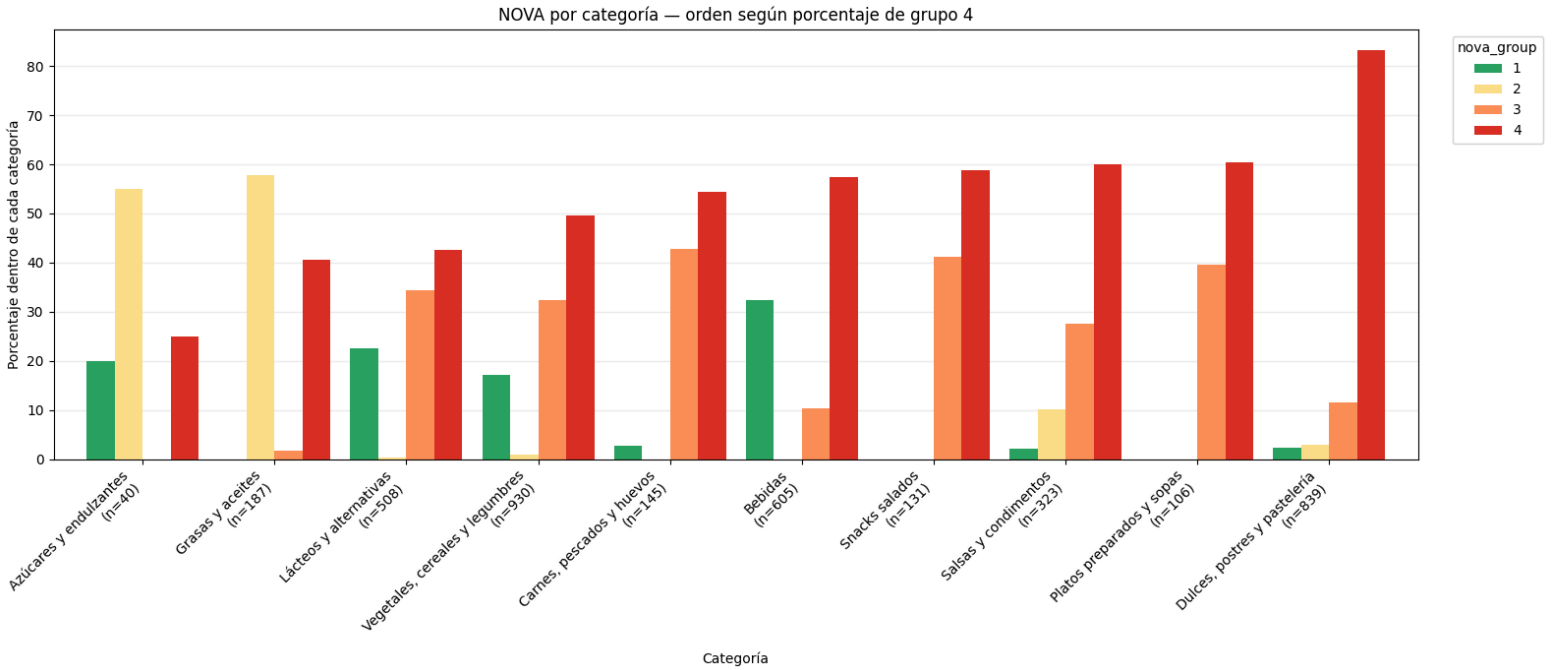


Fig 4: Gráfico de barras agrupadas por categoría, muestran porcentaje de productos con los distintos valores NOVA, ordenados por porcentaje de productos en grupo 4.

A partir de la figura 3, observamos que “platos preparados y sopas”, “carnes, pescados y huevos” y “bebidas” presentan las mayores proporciones de productos con Eco-Score F entre los registros con calificación válida de la muestra. Este resultado puede contextualizarse, en particular, la ganadería genera emisiones de metano durante la digestión de los animales y los mataderos y las plantas de procesamiento de carne generan residuos contaminantes. En la producción de bebidas, incluidas las gaseosas, interviene el uso de agua para la creación y la limpieza. Con respecto a los platos preparados, puede deberse a un alto uso de conservantes y ultra-procesamiento.

A partir de la figura 4, observamos que todas las categorías tienen un porcentaje considerable de ultraprocesados, en particular “dulces, postres y pastelería” tiene más de un 80% de alimentos asociados al grupo 4 nova. Los productos más esenciales (azúcares, aceites, lácteos y vegetales) tienen una mayor cantidad de alternativas no ultra procesadas.

Reducción de dimensionalidad

Para continuar con el análisis exploratorio de los datos, decidimos utilizar PCA (Análisis de Componentes Principales), que nos permite reducir la cantidad de variables sin perder demasiada información [Sección 7].

Para esto seleccionamos 8 variables cuantitativas: calorías, grasas, grasas saturadas, carbohidratos, azúcares, fibra, proteínas y sal. Primero eliminamos los registros que tenían valores nulos en alguna de estas variables. Después estandarizamos las variables para evitar que las diferencias de escala y varianza dominen el análisis.

Al aplicar PCA obtuvimos 8 componentes principales. El primero explica un 32,53% de la variabilidad de los datos y el segundo un 20,48%. Entre los dos explican un 53,01% de la variabilidad total. Si tenemos en cuenta los primeros 3 componentes llegamos al 70,11%, mientras que con los primeros 5 alcanzamos un 90,01%.

Esto nos permite observar que podemos reducir la cantidad de variables y seguir conservando gran parte de la información original. Sin embargo, si utilizamos solamente los primeros dos componentes, estaríamos perdiendo casi la mitad de la variabilidad.

Para entender mejor qué representa cada componente, realizamos un gráfico donde se muestra el peso que tiene cada nutriente en los primeros dos componentes principales [Sección 7.1].

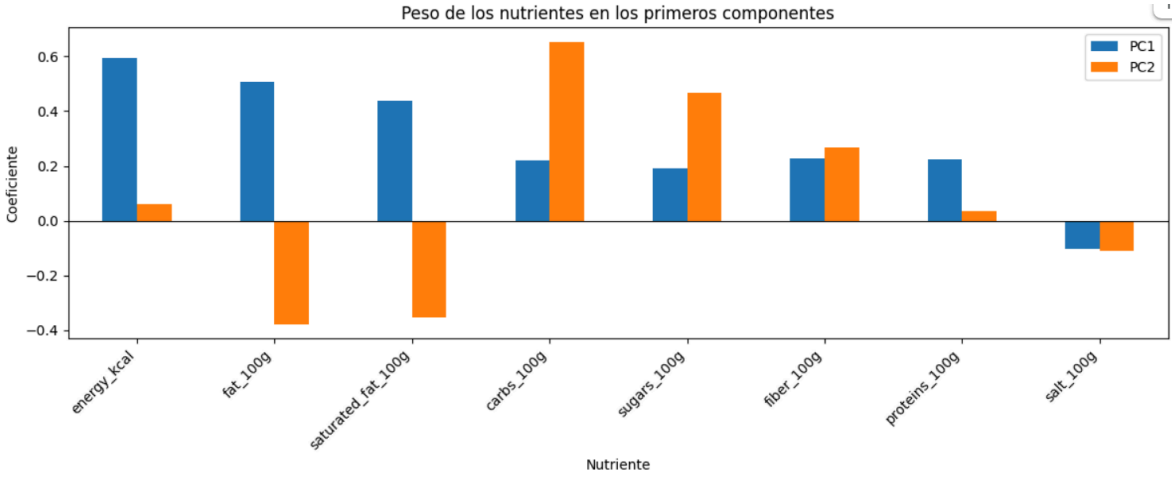


Fig 5: Gráfico de barras en el que muestran el coeficiente aportado por cada nutriente en los componentes PC1 y PC2 obtenidos con PCA.

Al observar el gráfico, vemos que en el primer componente (PC1) las variables con mayor peso son las calorías, las grasas y las grasas saturadas. Esto nos indica que este componente está principalmente relacionado con el contenido energético y las grasas de los productos.

En cambio, en el segundo componente (PC2) los carbohidratos y los azúcares tienen los valores positivos más altos, mientras que las grasas y las grasas saturadas presentan valores negativos. Esto significa que este componente permite diferenciar los productos con mayor contenido de carbohidratos y azúcares de aquellos que tienen mayor cantidad de grasas.

Graficamos PCA diferenciando los grupos NOVA [Sección 7.2] y el eco_score [Sección 7.3].

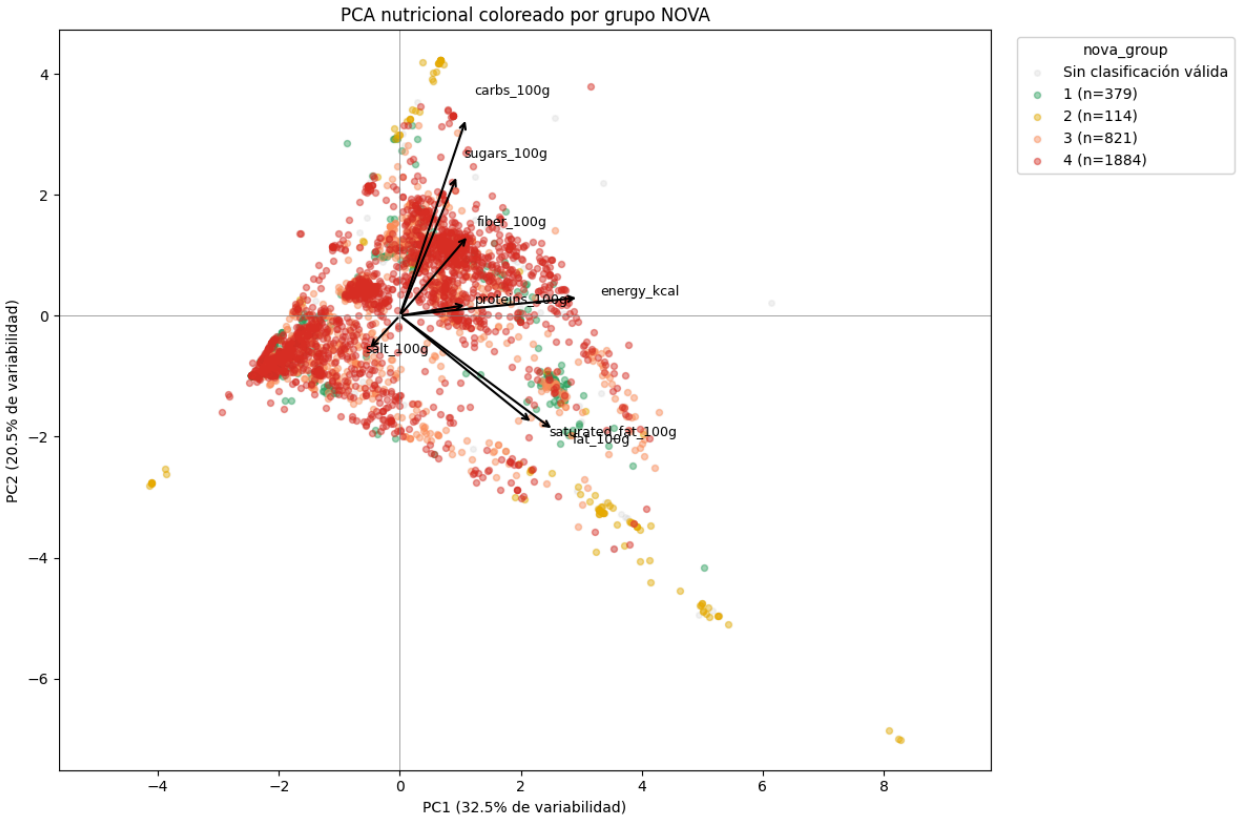


Fig 6: Gráfico scatterplot de PC1 y PC2 coloreado por grupos de NOVA.

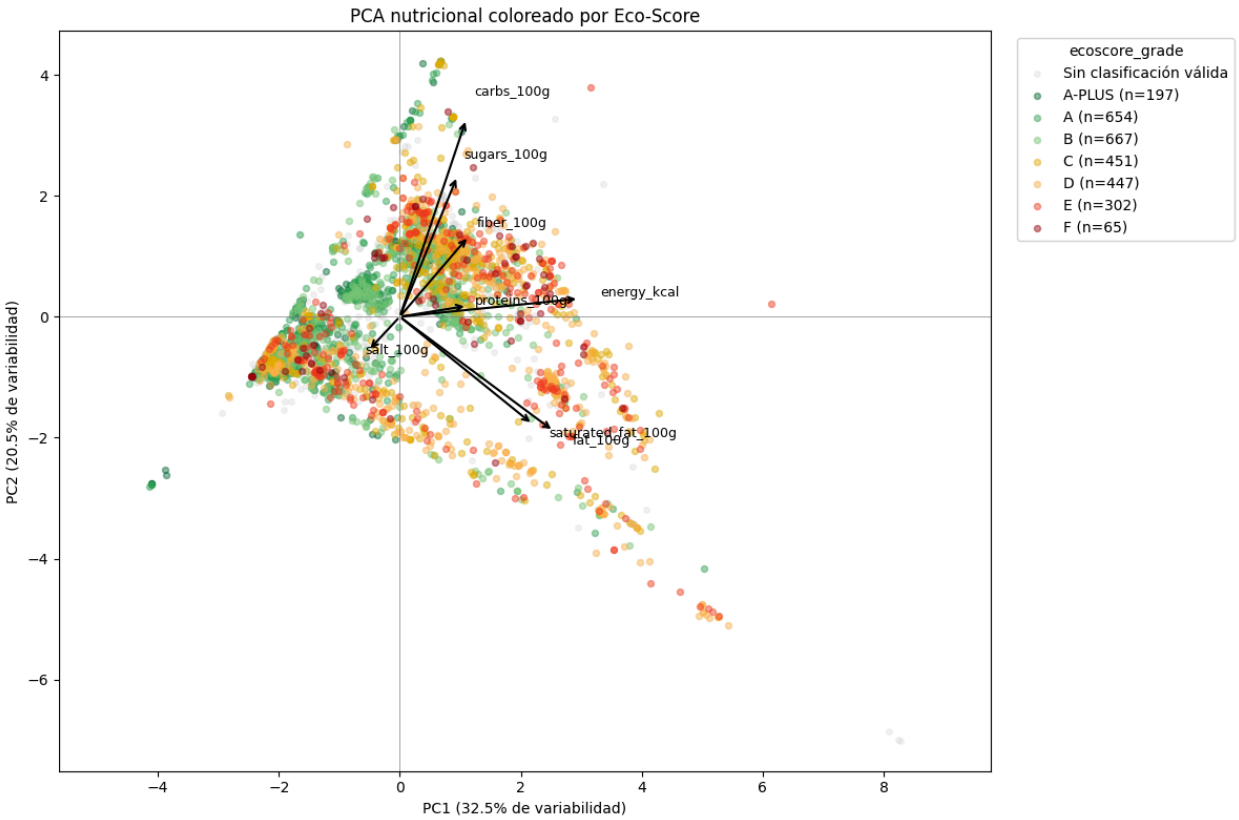


Fig 7: Gráfico scatterplot de PC1 y PC2 coloreado por grupos de ecoscore.

No observamos grupos claramente marcados en los gráficos, ni una relación que pudiéramos llegar a analizar futuramente como causal entre los componentes del PCA y el nova_group o el ecoscore. En el gráfico de PCA coloreado por Eco-Score vemos que los productos catalogados con A PLUS, A y B se encuentran agrupados hacia el centro, donde los valores nutricionales son menores. En el gráfico de PCA coloreado por NOVA vemos que el grupo 4 tiene muchos registros esparcidos por todo el espacio. Tenemos en cuenta además que estos dos componentes explican tan sólo un 53% de la variabilidad.

En conclusión, con PCA pudimos resumir la información nutricional de los productos en menos variables, conservando una parte importante de la variabilidad de los datos. Además, pudimos identificar qué nutrientes tienen mayor influencia en los primeros componentes, lo que nos permite comprender mejor cómo se relacionan las distintas características nutricionales de los alimentos.

3. Hipótesis y resolución

3.1. Hipótesis 1 (univariada):

3.1.1. Definición de la hipótesis

Más del 75% de los productos en la población de referencia pertenecen al grupo 3 o 4 nova. [Sección 8]

H0 : p <= 0.75

H1 : P > 0.75

3.1.2. Estrategia de abordaje

No conocemos exactamente el método de muestreo utilizado para obtener los datos. Suponemos una muestra aleatoria de productos. Realizamos una prueba unilateral para una proporción, con un nivel de significancia del 5%. Nos basamos solamente en productos que tengan nova disponible.

3.1.3. Resultados obtenidos y discusión

- Productos con NOVA válido: 4410
- Productos NOVA 3 o 4: 3637
- Proporción observada: 82.47%
- Intervalo unilateral de confianza del 95%: [81.50%, 100.00%]
- Valor p: 6.771e-33

Se rechaza H0: existe evidencia estadística de que más del 75% de los productos con NOVA válido pertenecen a los grupos 3 o 4.

Los resultados muestran que hay una gran cantidad de productos procesados y ultraprocesados, lo que genera preocupación, ya que estos alimentos suelen ser menos saludables. Esto nos lleva a pensar en la importancia de tener en cuenta tanto el nivel de procesamiento como la información nutricional al momento de elegir qué comer. Hoy en día, una persona que quiere alimentarse de manera más saludable tiene pocas opciones para elegir, porque la mayoría de los productos que se venden son procesados y ultraprocesados.

3.2. Hipótesis 2 (bivariada):

3.2.1. Definición de la hipótesis

Los productos de los grupos NOVA 3 y 4 presentan una mayor proporción de calificaciones Eco-Score E o F que los productos de los grupos NOVA 1 y 2. [Sección 9]

3.2.2. Estrategia de abordaje

Excluimos los registros sin eco-score o grupo nova válido. Posteriormente utilizamos una prueba Z con un nivel de significancia del 5% para determinar si la proporción de productos del grupo nova 3/4 con Eco-Score E o F es mayor que la proporción de productos con Eco-Score E o F del grupo nova 1/2.

3.2.3. Resultados obtenidos y discusión

	Eco-Score E/F	Otros grados válidos	Porcentaje de E/F
NOVA 3/4	451	2523	15.16
NOVA 1/2	88	518	14.52

- Estadístico Z: 0.4036
- Valor p: 0.343249

Planteamos esta hipótesis porque un mayor grado de procesamiento podía implicar un mayor consumo energético y utilización de recursos, por lo que esperábamos encontrar una mayor proporción de calificaciones ambientales negativas en los productos NOVA 3/4.

No se rechaza H0. No hay evidencia estadística suficiente para concluir que la proporción de Eco-Score E/F sea mayor en NOVA 3/4.

No encontramos evidencia estadística suficiente para respaldar esa diferencia. Una posible explicación es que también intervengan los métodos de producción, los envases y el transporte.

3.3. Hipótesis 3 (multivariada):

3.3.1. Definición de la hipótesis

1. Los productos NOVA 4 tienen, en promedio, más azúcar que los productos NOVA 1/2/3, al comparar dentro de la misma categoría alimentaria. [Sección 10]
2. A igual categoría alimentaria, los productos NOVA 4 tienen mayor probabilidad de presentar un alto contenido de azúcares (más de 10 g/100 g) que los productos NOVA 1/2/3. [Sección 10.1] (*)

3.3.2. Estrategia de abordaje

El objetivo de este análisis es ver si los alimentos ultraprocesados tienen más azúcar que otros alimentos de su misma categoría. Para esto, se filtraron los datos, dejando solo los productos con clasificación NOVA y valores de azúcar válidos, y se eliminaron categorías poco claras como "Otros". Luego, se realizó una Regresión Lineal Múltiple para analizar la relación entre ser ultraprocesado (NOVA 4) y la cantidad de azúcar, teniendo en cuenta también la categoría del alimento.

Posteriormente, se realizaron pruebas analíticas (Shapiro-Wilk) y gráficos (Q-Q plot) sobre los residuos para comprobar si cumplían con el supuesto de normalidad que requiere la regresión lineal.

Al observar que los residuos no se distribuían de forma normal, decidimos complementar el análisis implementando una Regresión Logística (*), porque este modelo no exige normalidad en los errores. Para poder aplicarla, transformamos la cantidad de azúcar en una variable binaria (alto_azucar), definiendo como umbral un contenido mayor a 10 gramos de azúcar cada 100 gramos de producto (toma el valor 1 si supera los 10 g/100g y 0 en caso contrario). De esta forma, evaluamos si pertenecer al grupo NOVA 4 aumenta la probabilidad de que un producto sea alto en azúcares, tanto en un modelo simple como controlando por su categoría alimentaria

3.3.3. Resultados obtenidos y discusión

SIN considerar la categoria del producto	
coef. NOVA 4	6.589 g/100g
R^2	0.033
AIC	31192
BIC	31205

Considerando la categoria del producto	
coef. NOVA 4	2.210 g/100g
R^2	0.443
AIC	29199
BIC	29267

- Shapiro-Wilk de los residuos: p = 9.203e-58

Al comparar los modelos, vemos que la categoría del alimento influye mucho en la cantidad de azúcar (el R^2 pasa de 3,3% a 44,3%). Sin embargo, incluso teniendo en cuenta la categoría, los productos NOVA 4 siguen teniendo en promedio 2,21 gramos más de azúcar cada 100 gramos (p menor a 0,001).

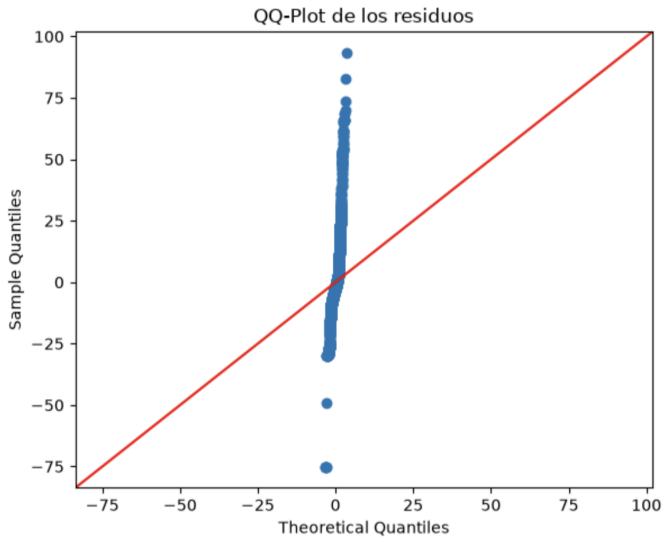


Fig 8: Gráfico Q-Q plot que analiza normalidad de residuos.

Por otro lado, la prueba de Shapiro-Wilk mostró que los residuos no tienen una distribución perfectamente normal. Esto también se puede ver en el gráfico Q-Q plot (figura 8), donde la distribución no sigue la recta de normalidad (está distribuida en una recta demasiado vertical). De todas formas, al trabajar con una muestra grande (3640 productos), los resultados del modelo siguen siendo confiables.

Se prosiguió con una regresión logística. [Sección 10.1]

3.3.4 Resultados obtenidos y discusión (Regresión Logística)

- Proporción de productos altos en azúcar (mas de 10 g cada 100g): 29,2%
- Proporción de productos bajos en azúcar: 70,8%.

Utilizamos este umbral ya que nos pareció el más apropiado para dividir esta variable en dos posibles resultados. Este valor es usado para determinar grandes cantidades de azúcar en muchos países, como por ejemplo está respaldado en una ley chilena.

SIN considerar la categoría del producto (Logit simple):

- coef. NOVA 4 = 1.2356
- Estadístico Z = 14.626
- Valor p < 0.001

Considerando la categoría del producto (Logit múltiple):

- Estadístico Z= 6.5551
- Valor p = 5.56151e-11

Para corroborar los resultados sin depender del supuesto de normalidad de los residuos, analizamos la Regresión Logística. Al transformar en binaria la variable, vimos que el 29,2% de los productos analizados supera los 10 g de azúcar cada 100 g. En el modelo logístico simple (considerando solo NOVA 4), el coeficiente fue de 1,2356 (Z=14,626 y p<0,001), y al incorporar la categoría del alimento como variable de control, el efecto de pertenecer a NOVA 4 se mantuvo positivo y altamente significativo.

Se rechaza H0: dentro de una misma categoría alimentaria, los productos NOVA 4 tienen mayor probabilidad de superar los 10 g de azúcar cada 100 g que los productos NOVA 1/2/3. El modelo lineal indica una diferencia media de 2,21 g/100 g, pero como sus residuos no cumplen el supuesto de normalidad, esa estimación se toma solo como descriptiva.

Esto demuestra que el exceso de azúcar no depende solamente del tipo de alimento, sino que el grado de ultraprocesamiento industrial aumenta de manera directa tanto la cantidad promedio de azúcar como las chances de que el producto sea alto en azúcares.

3.4. Hipótesis 4 (a):

3.4.1. Definición de la hipótesis

La proporción de productos catalogados como "altos en grasas saturadas" (más de 5 g de grasa saturada por cada 100 g de producto) en la población de referencia es superior al 25%. [Sección 11]

3.4.2. Estrategia de abordaje

Excluimos los registros sin datos válidos de grasas saturadas. Posteriormente, utilizamos una prueba binomial unilateral para una proporción, con un nivel de significancia del 5%, para determinar si la proporción de productos con más de 5 g de grasas saturadas por cada 100 g de producto es superior al 25%.

3.4.3. Resultados obtenidos y discusión

- Productos con datos válidos de grasas saturadas: 4513
- Productos altos en grasas saturadas (> 5 g/100 g): 1381
- Proporción observada: 30.60%
- Intervalo unilateral de confianza del 95%: [29.47%, 100.00%]
- Valor p: 1.11e-17

Se rechaza H0: existe evidencia estadística de que más del 25% de los productos de la población de referencia son catalogados como "altos en grasas saturadas" según el criterio establecido.

Los resultados muestran que el 30,60% de los productos analizados supera los 5 g de grasas saturadas por cada 100 g de producto, una proporción mayor al 25% planteado en la hipótesis. La diferencia es estadísticamente significativa, por lo que los datos respaldan nuestra hipótesis inicial. Esto demuestra que una parte considerable de los productos de la población de referencia presenta un contenido elevado de grasas saturadas, según el criterio establecido.

3.5. Hipótesis 5 (b):

3.5.1. Definición de la hipótesis

El grado de procesamiento industrial de un alimento está asociado con la calificación nutricional Nutri-Score que recibe, de manera que los productos más procesados presentan calificaciones más desfavorables. [Sección 12]

Es de utilidad entender si los alimentos ultraprocesados, que a menudo dominan el mercado, como vimos con los resultados de la hipotesis 3.1, también tienden a tener un peor perfil nutricional. Para guiar a los consumidores hacia elecciones alimentarias más saludables es importante analizar esta relación.

H0: La proporción de Nutri-score D/E en NOVA 3/4 es menor o igual que en NOVA 1/2.

H1: La proporción de Nutri-score D/E en NOVA 3/4 es mayor que en NOVA 1/2.

3.5.2. Estrategia de abordaje

Se eliminaron los productos que no tenian una clasificación NOVA o Nutri-score válida, quedando 4075 productos. Para comprobar la hipótesis, se utilizó una prueba Z con un nivel de significancia del 5%, comparando cuántos productos de cada grupo (NOVA 1/2 y NOVA 3/4) tienen un grado nutricional bajo (D o E).

3.5.3. Resultados obtenidos y discusión

	Nutri-Score A/B/C	Nutri-Score D/E	Porcentaje D/E
NOVA 3/4	1812	1584	46.64
NOVA 1/2	540	139	20.47

- Estadístico Z: 12.6025
- Valor p: 1.02331e-36

Se rechaza H0: Existe evidencia estadística de una mayor proporción de calificaciones Nutri-Score desfavorables (D/E) en alimentos ultraprocesados (NOVA 3/4) que en alimentos no procesados o con mínimo procesamiento (NOVA 1/2).

El valor p, que es casi nulo, muestra una relación entre el procesamiento industrial y una peor calidad nutricional. El 46,64% de los productos procesados y ultraprocesados obtuvo las peores calificaciones de Nutri-Score, más que el doble que los menos procesados. Esto muestra que la clasificación NOVA puede ayudar a identificar la calidad nutricional de los alimentos.

3.6. Hipótesis 6 (c):

3.6.1. Definición de la hipótesis

El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos declarados explican conjuntamente la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable (D/E), sin utilizar directamente su composición nutricional. [Sección 13]

3.6.2. Estrategia de abordaje

Se eliminaron los productos que no tenían una clasificación NOVA válida (del 1 al 4), una categoría definida o un Nutri-Score válido (de A a E). También se contó la cantidad de alérgenos que tenía cada producto. Después, se realizó un modelo de Regresión Logística para calcular la probabilidad de que un producto tuviera un Nutri-Score D o E, teniendo en cuenta su clasificación NOVA, su categoría y la cantidad de alérgenos declarados. Por último, se aplicó una prueba LRT, con un nivel de significancia del 5%, para comprobar si estas variables ayudaban a predecir el Nutri-Score mejor que un modelo sin variables explicativas.

3.6.3. Resultados obtenidos y discusión

Productos considerados	3549
Productos excluidos	1291
R^2 de McFadden	0.2803

- Estadístico LR: 1364.6532
- Grados de libertad: 13
- Valor p: 6.31791e-284 ($p < 0.001$)

La hipótesis plantea que características del producto, como su nivel de procesamiento, su categoría y la cantidad de alérgenos, pueden ayudar a predecir si es nutricionalmente desfavorable sin tener que revisar su tabla nutricional.

Se rechaza H0. Existe evidencia estadística de que el grado de procesamiento (NOVA), la categoría del producto y la cantidad de alérgenos declarados explican conjuntamente la probabilidad de recibir un Nutri-Score desfavorable (D/E).

Como el valor p fue prácticamente cero (p menor a 0,05), rechazamos la hipótesis nula. Esto indica que el nivel de procesamiento, la categoría y la cantidad de alérgenos ayudan a explicar si un producto tiene un Nutri-Score desfavorable. Además, los resultados muestran que los niveles NOVA 2, 3 y 4 y una mayor cantidad de alérgenos aumentan la probabilidad de obtener una calificación D o E. Esto sugiere que estas características están relacionadas con una peor calidad nutricional.

4. Conclusiones

En este trabajo práctico, a partir del análisis de la base de datos Global Food & Nutrition 2026, pudimos estudiar la calidad nutricional de los alimentos que encontramos actualmente en el mercado. Después de analizar los datos, observamos que más del 75% de los productos pertenecen a los grupos NOVA 3 y 4, es decir, son procesados y ultraprocesados. Lo cual era de esperarse porque la base de datos presenta productos disponibles en el mercado actual, donde hay una gran presencia de alimentos industrializados. Cuando vamos a un supermercado, la mayoría de las góndolas tienen productos con conservantes y otros aditivos.

A través de las distintas pruebas realizadas, comprobamos que los alimentos más procesados suelen tener una peor calidad nutricional. Esto se ve reflejado en una mayor cantidad de productos con Nutri-Score D o E y en que los ultraprocesados contienen más azúcar que otras opciones menos procesadas de su misma categoría. Además, encontramos que más del 25% de los productos tienen un alto contenido de grasas saturadas. Esto es un nivel muy alto dado que las grasas saturadas se asocian con alimentos que se recomienda consumir en cantidades bajas debido a sus posibles efectos negativos sobre la salud.

No encontramos una relación estadísticamente significativa entre el nivel de procesamiento industrial y un peor impacto ambiental (Eco-Score E o F). Inicialmente suponíamos que, a mayor nivel de procesamiento e industrialización, el daño ecológico iba a ser mayor, pero los resultados nos permitieron concluir que la relación no es tan directa y que influyen otros factores propios de cada categoría, como el impacto de la ganadería en las carnes o el uso de recursos en el envasado y transporte. Asimismo, mediante regresión logística pudimos comprobar que el nivel NOVA, la categoría del alimento y la cantidad de alérgenos declarados permiten predecir

conjuntamente si un producto tendrá una mala calificación nutricional, sin necesidad de utilizar directamente su tabla de nutrientes.

En conclusión, este trabajo nos permitió entender mejor cómo está relacionado el procesamiento industrial con la calidad de los alimentos y con otras variables. Hoy en día hay una gran cantidad de ultraprocesados en el mercado, entonces es importante contar con información y conocer en que factores depende que un producto sea perjudicial o no para nuestra salud. Esto nos ayuda a elegir mejor los alimentos y a mantener una alimentación más equilibrada.

Referencias

- Ahsan Neural. (s. f.). Global food & nutrition database 2026 [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/ahsanneural/global-food-and-nutrition-database-2026/data
- U.S. Department of Agriculture. (s. f.). FoodData Central. https://fdc.nal.usda.gov/
- Open Food Facts. (s. f.). Open Food Facts: Base de datos abierta de productos alimenticios. https://es.openfoodfacts.org/
- Organización Mundial de la Salud. (2026, 26 de enero). Alimentación saludable. https://www.who.int/es/news-room/fact-sheets/detail/healthy-diet
- D-Carbonize. (2026, 20 de febrero). Eco-score: All about this label. https://d-carbonize.eu/eco-score/
- Open Food Facts. (s. f.). Nutri-Score. https://es.openfoodfacts.org/nutriscore
- European Food Information Council. (2025, 1 de agosto). Lista de los 14 alérgenos alimentarios más comunes. https://www.eufic.org/es/vida-sana/articulo/lista-de-los-14-alergenos-alimentarios-mas-comunes
- Open Food Facts. (s. f.). Descubra la clasificación en 5 colores A-B-C-D-E de 10.000 alimentos en Open Food Facts. https://blog.openfoodfacts.org/es/news/descubra-la-clasificacion-en-5-colores-a-b-c-d-e-de-10-000-alimentos-en-open-food-facts
- Escuela de Posgrado de Salamanca. (2025, 13 de abril). ¿Qué es el valor nutricional de los alimentos? https://posgradosalamanca.lat/blog/que-es-valor-nutricional-como-medir/